

Segmentacija Soli u Seizmičkim Slikama: Teorijska Osnova

Kontrolna tačka 1

Principi prezentacije i prepoznavanje oblika

Predmet: Principi prezentacije i prepoznavanja
oblika

Predmetni nastavnik: Marko Arsenović

Asistent: Sofija Đorđević

Student: Ljuban Opačić IT2/2022

Novi Sad, 2025. godina

Sadržaj

1. Uvod u problem	2
1.1. Segmentacija solnih struktura	2
1.2. Značaj segmentacije soli u geofizici i naftnoj industriji	2
1.3. Izazovi segmentacije soli	3
2. Pregled literature i postojećih pristupa.....	4
2.1. Tradicionalni pristupi pre ere dubokog učenja.....	4
2.2. Revolucija dubokog učenja u segmentaciji soli.....	4
2.3. Hronološki razvoj i ključni radovi	5
3. Najčešće Korišćeni Algoritmi i Modeli	7
3.1 U-Net arhitektura i varijante	7
3.2 CNN arhitekture kao enkodori	7
3.3 Encoder–Decoder arhitekture	8
3.4 Attention mehanizmi i transformeri	8
3.5 Loss funkcije.....	8
3.6 Poređenje metoda.....	9
4. Komentar i Ideje Studenta	11
4.1 Analiza Najefikasnijih Metoda	11
4.2 Predlog Pristupa za Istraživanje.....	11
4.3 Vizija i Očekivanja.....	12
5. Reference	14

1. Uvod u problem

1.1. Segmentacija solnih struktura

Segmentacija soli predstavlja proces automatske identifikacije i precizne delineacije solnih tela (*salt bodies*) u seizmičkim slikama Zemljine kore. Solna tela su geološke formacije sastavljene od halogenih minerala, najčešće halita (natrijum-hlorida), koje nastaju taloženjem u drevnim morskim i jezerskim sredinama. Tokom dugotrajnih geoloških procesa, ove formacije mogu razviti kompleksne morfološke oblike, uključujući solne domove (*salt domes*), solne zidove (*salt walls*) i solne jastučice (*salt pillows*), koji imaju značajnu ulogu u strukturi sedimentnih basena [1].

U kontekstu računarske vizije i mašinskog učenja, segmentacija soli se posmatra kao zadatak semantičke segmentacije, čiji je cilj klasifikacija svakog piksela seizmičke slike u jednu od dve klase: „so“ ili „ne-so“ (sediment). Seizmičke slike se dobijaju metodom seizmičke refleksije, pri čemu se akustični talasi emituju u podzemlje, a njihovi reflektovani signali se registruju na površini. Različite geološke formacije karakterišu različite akustične impedanse, što dovodi do razlika u reflektovanom signalu. Ove razlike se vizualizuju kao varijacije intenziteta piksela na seizmičkim slikama, omogućavajući indirektno razlikovanje različitih litoloških jedinica [2].

1.2. Značaj segmentacije soli u geofizici i naftnoj industriji

Precizna identifikacija i mapiranje solnih struktura imaju ključni značaj u geofizici, naročito u kontekstu istraživanja i eksploatacije nafte i prirodnog gasa. Jedan od osnovnih razloga leži u činjenici da solna tela često formiraju strukturne zamke (*structural traps*) u kojima se mogu akumulirati značajne rezerve ugljovodonika. Zbog svoje izuzetno niske permeabilnosti, so deluje kao efikasna barijera koja sprečava migraciju fluida, čime se stvaraju povoljni uslovi za zadržavanje nafte i gasa ispod ili u neposrednoj blizini solnih formacija [1], [3].

Pored toga, tačno poznavanje geometrije i prostornog rasporeda solnih tela od presudnog je značaja za planiranje putanje bušenja. Bušenje kroz solne formacije predstavlja ozbiljan tehnički izazov usled plastičnog ponašanja soli i njene sklonosti ka deformaciji i „tečenju“ pod visokim pritiskom, što može dovesti do zatvaranja bušotine ili oštećenja opreme. Detaljno mapiranje solnih struktura omogućava inženjerima da projektuju optimalne putanje bušenja, bilo da se ove zone izbegavaju ili da se primene odgovarajuće tehničke mere za njihovo savladavanje [4].

Dodatno, solna tela se odlikuju seizmičkim brzinama koje se značajno razlikuju od brzina okolnih sedimentnih stena. Ova razlika ima snažan uticaj na propagaciju seizmičkih talasa i može izazvati ozbiljne distorzije u seizmičkim slikama ukoliko se ne uzme u obzir tokom obrade podataka. Precizno modelovanje solnih struktura predstavlja neophodan korak u procesu seizmičke migracije i izgradnje modela brzina, što direktno utiče na kvalitet konačnih seizmičkih zapisa i tačnost geološke interpretacije podzemnih struktura [5].

Ekonomski aspekt ovog problema je takođe izuzetno značajan. Tradicionalni pristup manuelne interpretacije solnih struktura, koji se oslanja na rad iskusnih geofizičkih stručnjaka, izuzetno je vremenski zahtevan i skup, naročito u slučaju velikih 3D seizmičkih istraživanja. Ovakav proces može trajati mesecima, što značajno usporava donošenje poslovnih odluka. Automatizacija segmentacije soli putem metoda mašinskog učenja ima potencijal da značajno smanji vreme i troškove analize, čime se omogućava efikasnije i brže upravljanje istraživačkim i proizvodnim procesima [6].

1.3. Izazovi segmentacije soli

Uprkos velikom praktičnom značaju, segmentacija soli u seizmičkim slikama predstavlja izuzetno složen i izazovan problem, uslovljen nizom faktora.

Jedan od glavnih izazova jeste izrazita varijabilnost oblika i dimenzija solnih tela. Ove strukture mogu varirati od relativno jednostavnih i kompaktnih geometrija do veoma kompleksnih, nepravilnih oblika sa izraženim ivicama, prevlakama i diskontinuitetima. Takva raznovrsnost otežava razvoj univerzalnih modela koji bi bili sposobni da generalizuju na širok spektar mogućih konfiguracija solnih struktura [2], [7].

Dodatni problem predstavlja prisustvo šuma i ograničena rezolucija seizmičkih podataka. Seizmičke slike su inherentno opterećene različitim vrstama šuma, uključujući ambijentalni šum, višestruke refleksije i artefakte nastale tokom akvizicije podataka. Pored toga, ograničen frekventni opseg i relativno niska prostorna rezolucija često otežavaju razaznavanje finih detalja, naročito u zonama granice između soli i okolnih sedimenata [6], [8].

Problem neuravnoteženosti klasa predstavlja još jedan značajan izazov u ovom domenu. U većini seizmičkih slika, solna tela zauzimaju relativno mali deo ukupne površine u poređenju sa sedimentima. Ovakva izražena neuravnoteženost klasa može dovesti do toga da modeli mašinskog učenja favorizuju predviđanje dominantne klase, što rezultuje slabom detekcijom soli, iako je upravo ta klasa od najvećeg interesa [9], [10].

Nejasno definisane granice između soli i okolnih formacija dodatno komplikuju proces segmentacije. Efekti kao što su prelazne zone, delimični volumenski efekat (*partial volume effect*) i ograničena rezolucija često dovode do postepenih, a ne oštarih prelaza između različitih litologija. Ovo otežava preciznu delineaciju granica solnih tela, čak i za iskusne interpretere [11].

Konačno, značajan problem predstavlja i ograničena dostupnost kvalitetno anotiranih podataka. Kreiranje pouzdanih *ground truth* anotacija zahteva angažovanje visoko specijalizovanih geofizičkih stručnjaka i značajnu količinu vremena, što rezultuje malim brojem velikih i dobro anotiranih skupova podataka. Ovaj nedostatak direktno utiče na mogućnosti treniranja robusnih modela dubokog učenja [2], [12].

Pored navedenog, problem generalizacije modela ostaje otvoreno pitanje. Modeli trenirani na seizmičkim podacima iz jednog geografskog regiona ili dobijeni specifičnim akvizicionim sistemima često pokazuju značajno smanjen učinak prilikom primene na podatke iz drugih regiona sa drugačijim geološkim i seizmičkim karakteristikama. Ova ograničena sposobnost generalizacije predstavlja jednu od glavnih prepreka za širu industrijsku primenu automatizovanih metoda segmentacije soli [6], [13].

2. Pregled literature i postojećih pristupa

2.1. Tradicionalni pristupi pre ere dubokog učenja

Pre pojave metoda dubokog učenja, segmentacija soli u seizmičkim slikama se u velikoj meri oslanjala na konvencionalne tehnike obrade slike i ručnu interpretaciju podataka od strane geofizičkih stručnjaka. Tradicionalni pristupi su uključivali analizu različitih seizmičkih atributa, kao što su amplituda, faza, frekvencija i koherencija, koji su korišćeni kao indikatori prisustva solnih struktura. Na osnovu ovih atributa, primenjivani su algoritmi detekcije ivica (*edge detection*), uključujući Sobel, Canny i Prewitt operatore, sa ciljem identifikacije granica između različitih geoloških formacija [1].

Pored toga, metode zasnovane na pragu (*threshold-based methods*) bile su često korišćene za klasifikaciju piksela na osnovu njihovih intenzitetskih vrednosti. Iako su ove metode relativno jednostavne za implementaciju, pokazale su značajna ograničenja u radu sa šumnim podacima i kompleksnim geometrijama solnih tela. Njihova primena je često zahtevala ručno podešavanje parametara za svaki pojedinačni skup podataka, što je otežavalo njihovu skalabilnost i praktičnu primenu [1], [8].

Napredak u odnosu na navedene pristupe predstavljali su *graph cut* algoritmi, koji su omogućavali globalno optimizovanu segmentaciju putem minimizacije energetske funkcije. Ovi algoritmi su pokazali poboljšane performanse u odnosu na jednostavne lokalne metode, ali su i dalje zahtevali pažljivo ručno dizajniranje ulaznih karakteristika (*feature engineering*). Pored toga, njihova robusnost je bila ograničena u uslovima ekstremne varijabilnosti oblika i veličina solnih struktura, što je predstavljalo značajan nedostatak u realnim seizmičkim primenama [1].

2.2. Revolucija dubokog učenja u segmentaciji soli

Pojava dubokog učenja, a naročito konvolucionih neuronskih mreža (CNN), donela je fundamentalne promene u pristupu segmentaciji soli u seizmičkim slikama. Za razliku od tradicionalnih metoda koje se oslanjaju na ručno definisane karakteristike, CNN modeli su sposobni da automatski uče hijerarhijske reprezentacije direktno iz sirovih podataka. Ova sposobnost omogućava modelima da efikasno uhvate složene obrasce, teksture i prostorne odnose prisutne u seizmičkim zapisima, čak i u uslovima visokog nivoa šuma i varijabilnosti podataka [2], [7].

Prelomni trenutak u primeni dubokog učenja na problem segmentacije soli predstavljao je TGS Salt Identification Challenge, Kaggle takmičenje organizovano 2018. godine u saradnji sa kompanijom TGS (Tomlinson Geophysical Services). Ovo takmičenje je obezbedilo javno dostupan skup podataka koji se sastojao od približno 4.000 seizmičkih slika sa odgovarajućim maskama segmentacije, čime je istraživačkoj zajednici omogućeno da razvija, poredi i validira različite pristupe na zajedničkom referentnom datasetu [14], [15].

Rezultati postignuti tokom TGS challenge-a jasno su pokazali superiornost metoda zasnovanih na dubokom učenju u odnosu na tradicionalne tehnike. Najuspešniji modeli su postigli Dice koeficijente veće od 0.85, što je predstavljalo značajan iskorak u tačnosti automatske segmentacije soli. Ovi rezultati su podstakli intenzivna istraživanja i razvoj novih arhitektura dubokog učenja specijalizovanih za ovaj problem [2], [9].

2.3. Hronološki razvoj i ključni radovi

Razvoj metoda za segmentaciju soli zasnovanih na dubokom učenju može se posmatrati kroz hronološki pregled ključnih istraživačkih radova, koji ilustruju evoluciju pristupa, arhitektura i metodoloških rešenja.

2018 – Početak ere dubokog učenja za segmentaciju soli.

Karchevskiy i saradnici [7] bili su među prvim istraživačima koji su primenili duboko učenje na problem automatske segmentacije solnih depozita. Njihov rad je demonstrirao potencijal CNN arhitektura za ovaj zadatak i postavio temelje za dalja istraživanja u ovoj oblasti. Poseban akcenat stavljen je na U-Net arhitekturu, pri čemu je pokazano da encoder–decoder struktura može efikasno da integriše kontekstualne informacije na različitim prostornim skalama.

2019 – Napredak u semi-supervised učenju i ensemble metodama.

Babakhin i saradnici [2] predstavili su semi-supervised pristup zasnovan na ansamblu konvolucionih neuronskih mreža za segmentaciju solnih tela. Njihova metoda je koristila neoznačene podatke kroz višekružni *self-training* proces, čime je delimično prevaziđen problem ograničene dostupnosti anotiranih podataka. Na TGS datasetu, njihov ensemble pristup je ostvario značajna poboljšanja u odnosu na pojedinačne modele, potvrđujući efikasnost kombinovanja više prediktora.

U istom periodu, Sen i saradnici [6] fokusirali su se na problem generalizacije modela, uvodeći specijalizovane strategije regularizacije za U-shaped encoder–decoder CNN arhitekture. Njihov pristup je uključivao perturbaciju *ground truth* labela tokom procesa treniranja, što je delovalo kao snažan regularizacioni mehanizam i doprinelo smanjenju preučenja. Validacija na realnim seizmičkim podacima iz oblasti Meksičkog zaliva pokazala je poboljšanu robusnost modela pri primeni na nova istraživanja.

2020–2021 – Specijalizovane arhitekture i optimizacija ivica.

Milosavljević [9] je sproveo detaljnu studiju primene metoda dubokog učenja za semantičku segmentaciju solnih depozita u seizmičkim slikama, pružajući sveobuhvatnu analizu različitih arhitektura i njihovih performansi na TGS datasetu.

Guo i saradnici [11] razvili su algoritam zasnovan na dubokoj superviziji i optimizaciji ivica (*deep supervised edge optimization*), koji je bio specifično dizajniran za segmentaciju solnih struktura. Njihov pristup je eksplicitno modelovao granice solnih tela, čime je adresiran problem nejasno definisanih ivica, a rezultati su pokazali preciznije delineacije u poređenju sa standardnim metodama.

Li i saradnici [16] predstavili su model dubokog učenja za automatsku segmentaciju solnih stena, sa posebnim fokusom na praktičnu primenu u oblasti inženjerstva stena i mehanike.

2022 – Interaktivna segmentacija i hibridni pristupi.

Zhang i saradnici [1] predložili su SaltISCG, interaktivnu metodu segmentacije soli koja kombinuje konvolucione neuronske mreže i *graph cut* algoritme. Njihov pristup je transformisao pozitivne i negativne korisničke interakcione tačke u Euklidske distance mape (*Euclidean Distance Maps – EDM*), koje su potom kombinovane sa seizmičkim slikama. Model je koristio UNet arhitekturu sa *pyramid pooling* modulom (PPM), dok je *graph cut* algoritam služio za rafinaciju dobijenih mapa verovatnoće, omogućavajući korisnicima da interaktivno poboljšaju rezultate automatske segmentacije u praktičnoj primeni.

2023 – Napredne arhitekture i attention mehanizmi.

Saad i saradnici [17] razvili su *self-attention* potpuno konvolucione DenseNet arhitekture za automatsku segmentaciju soli. Integracijom attention mehanizama sa DenseNet strukturom omogućeno je modelu da se fokusira na najrelevantnije regione seizmičke slike, što je rezultovalo poboljšanim performansama u poređenju sa standardnim CNN arhitekturama.

Kiran i saradnici [4] kombinovali su U-Net arhitekturu sa ResNet enkoderom za identifikaciju solnih struktura u seizmičkim slikama. Korišćenje ResNet-a kao enkodera omogućilo je treniranje dubljih mreža uz stabilniju propagaciju gradijenata, što je dovelo do efikasnije ekstrakcije karakteristika.

2024 – Transformeri i generativna veštačka inteligencija.

Li i saradnici [18] predstavili su SaltFormer, hibridnu CNN–Transformer arhitekturu za automatsku detekciju solnih domova. Ovaj model je kombinovao lokalne karakteristike ekstraktovane pomoću CNN-a sa globalnim kontekstom obuhvaćenim Transformer enkoderom, postizujući rezultate koji se smatraju *state-of-the-art* u ovoj oblasti.

Souadih i saradnici [19] istraživali su primenu naprednih tehnika dubokog učenja, uključujući Transformere, generativnu veštačku inteligenciju i *liquid state machines*, za preciznu identifikaciju solnih domova. Njihovi rezultati su ukazali na značajan potencijal savremenih i emergentnih tehnologija u unapređenju tačnosti i robusnosti segmentacije.

Anitha i saradnici [20] razvili su unapređenu U-Net arhitekturu sa *mixed attention loss* funkcijom, sa ciljem boljeg rukovanja problemom neuravnoteženih klasa u semantičkoj segmentaciji solnih depozita.

Muller i saradnici [21] predstavili su Deep-Salt, pristup za kompletnu trodimenzionalnu segmentaciju soli iz netačno migriranih podzemnih *offset gather* podataka korišćenjem metoda dubokog učenja. Njihov rad je značajno proširio problem segmentacije soli na 3D domen, uvodeći dodatne izazove u pogledu prostorne konzistentnosti i računске složenosti.

3. Najčešće Korišćeni Algoritmi i Modeli

3.1 U-Net arhitektura i varijante

U-Net je dominantna arhitektura za segmentaciju soli u seizmičkim slikama. Posедуje simetričnu encoder–decoder strukturu (U-oblik) sa **skip connections**, koje omogućavaju dekoderu pristup visoko-rezolucionim karakteristikama iz enkodera. Ovaj pristup je ključan za očuvanje detalja i precizno određivanje granica solnih struktura [1], [7].

Na TGS datasetu, osnovna U-Net arhitektura daje dobre rezultate, dok su ensemble modeli (više U-Net mreža) postigli **Dice ~0.87** [2]. Varijante U-Net-a uključuju:

- **U-Net + Pyramid Pooling Module (PPM)**: bolja multi-scale reprezentacija i rukovanje različitim veličinama solnih tela [1].
- **MultiResU-Net**: multi-resolution feature blokovi za bolje procesiranje različitih rezolucija [22].
- **Enhanced U-Net sa mixed attention**: fokusiranje na relevantne regione slike putem attention mehanizama [20].

U-Net modeli tipično postižu **Dice 0.80–0.87**, a **IoU 0.75–0.82**. Njihove prednosti su efikasna multi-scale ekstrakcija feature-a i relativno manji broj parametara, dok su ograničenja vezana za slabu globalnu kontekstualnu reprezentaciju i probleme sa ekstremno malim ili velikim strukturama.

3.2 CNN arhitekture kao enkoderi

Pretrenirani CNN modeli često se koriste kao enkoderi u U-Net arhitekturama radi transfer learning-a. Najčešće korišćeni su:

- **ResNet** (ResNet-34/50/101): omogućava treniranje dubokih mreža putem residual konekcija. ResNet enkoderi daju **Dice 0.83–0.86** na TGS datasetu [4].
- **VGG**: karakteriše uniforman 3×3 kernel, ali zahteva više memorije i može dovesti do overfitting-a na manjim datasetima [23].
- **DenseNet**: dense konekcije poboljšavaju propagaciju feature-a i gradijenata, često postižući **Dice do 0.87** uz attention module [17].

Pretreniranjem na ImageNet-u postiže se brža konvergencija i bolja generalizacija, ali postoji rizik da se feature-i prirodnih slika ne prilagode optimalno seizmičkim podacima.

3.3 Encoder–Decoder arhitekture

Encoder–decoder dizajn je osnova semantičke segmentacije: enkoder kompresuje sliku u semantičku reprezentaciju, dok dekoder rekonstruše segmentacionu masku [6], [8].

Sen et al. [6] su koristili U-shaped arhitekturu sa regularizacijom, uključujući perturbaciju labela i smoothing, što je smanjilo overfitting i poboljšalo robusnost. Ensemble i test-time augmentation dodatno su povećali tačnost.

3D encoder–decoder pristupi, poput Deep-salt, obrađuju volumetrijske podatke i koriste 3D konvolucije ili ConvLSTM jedinice. Ove metode omogućavaju prostornu konzistentnost, ali zahtevaju znatne resurse [21].

3.4 Attention mehanizmi i transformeri

Attention mehanizmi omogućavaju modelima da fokusiraju pažnju na relevantne regione slike, što je ključno za razlikovanje soli od sedimenata [17], [20]. Self-attention DenseNet modeli postižu **Dice ~0.87**, jer hvataju long-range dependencies.

Transformeri, kao u SaltFormer modelu, kombinuju CNN encoder, Transformer encoder i CNN decoder, omogućavajući globalno modelovanje konteksta i bolje detekcije velikih solnih struktura [18]. Ipak, ovi modeli zahtevaju više memorije i vremena treniranja.

3.5 Loss funkcije

Zbog neuravnoteženih klasa, izbor loss funkcije značajno utiče na performanse:

- **BCE Loss:** standardna binarna cross-entropy, ali može favorizovati većinsku klasu [9], [10].
- **Dice Loss:** optimizuje preklapanje između predikcije i ground truth-a, efikasna za neuravnotežene datasete [2], [9], [10].
- **Focal Loss:** fokusira se na teško klasifikovane piksele, korisna za male solne strukture [10].

Najčešće se koristi kombinacija **BCE + Dice**, koja daje najbolje rezultate (Dice 0.85–0.87). Focal loss se preporučuje kada dataset sadrži mnogo malih struktura.

3.6 Poređenje metoda

Tabela 1 prikazuje poređenje najčešćih metoda za segmentaciju soli.

Metoda	Arhitektura	Dataset	Dice Coef.	IoU	Glavne prednosti	Glavna ograničenja	Ref.
Osnovni U-Net	U-Net	TGS	0.80–0.83	0.75–0.78	Jednostavnost, efikasnost	Ograničene performanse na kompleksnim strukturama	[7]
Ensemble CNN	Više U-Net modela	TGS	~0.87	~0.82	Robusnost, visoke performanse	Veća računarska složenost	[2]
U-Net + ResNet	U-Net decoder + ResNet encoder	TGS	0.83–0.86	0.78–0.81	Transfer learning, duboke feature-e	Više parametara, rizik od overfitting-a	[4]
SaltISCG	U-Net + PPM + Graph Cut	TGS	N/A	N/A	Interaktivna segmentacija, precizne granice	Zahteva korisničku interakciju	[1]
SelfAttention DenseNet	DenseNet + Self-Attention	TGS	~0.87	N/A	Long-range dependencies	Veća računarska složenost	[17]
SaltFormer	CNN + Transformer	Različiti	N/A	N/A	Globalni kontekst, state-of-the-art	Zahteva značajne resurse	[18]
Regularized U-Net	U-Net sa regularizacijom	Gulf of Mexico	N/A	N/A	Poboljšana generalizacija	Specifične regularizacione strategije	[6]
Edge-Optimized	Deep supervised edge optimization	TGS	N/A	N/A	Precizne granice	Fokus samo na ivice	[11]
Enhanced U-Net	U-Net + Mixed Attention Loss	TGS	~0.86	N/A	Bolje rukovanje neuravnoteženim klasama	Kompleksna loss funkcija	[20]
3D Deep-salt	3D U-Net / ConvLSTM	SEG/EAGE	N/A	N/A	3D konzistentnost	Visoki računski zahtevi	[21]

Ključna zapažanja:

- Ensemble modeli daju najbolje performanse, ali su računarski zahtevni [2].
- Attention i transformer pristupi pružaju state-of-the-art rezultate, ali zahtevaju više resursa [17], [18].
- U-Net ostaje temelj većine pristupa, a transfer learning značajno poboljšava rezultate [1], [4], [7].
- Kombinovane loss funkcije (BCE + Dice) najbolje rešavaju problem neuravnoteženih klasa [2], [9], [10].
- 3D modeli omogućavaju volumetrijsku segmentaciju, ali su zahtevni [21].

4.Komentar i Ideje Studenta

4.1 Analiza Najefikasnijih Metoda

Na osnovu detaljnog pregleda literature, mogu se identifikovati ključni faktori koji doprinose uspešnoj segmentaciji soli:

Arhitektonski izbor: U-Net arhitektura sa pretreniranim enkoderom (ResNet ili DenseNet) predstavlja optimalan balans između performansi i računske efikasnosti. Ensemble pristup sa 3-5 različitih modela može dodatno poboljšati rezultate za 2-3% u Dice koeficijentu, što može biti kritično za praktičnu primenu [2], [4].

Loss funkcija: Kombinacija Binary Cross-Entropy i Dice loss-a se pokazala kao najefikasnija za rukovanje neuravnoteženim klasama koje su inherentne u segmentaciji soli. Dodatno, weighted loss sa većim težinama na granicama solnih struktura može poboljšati preciznost delineacije [9], [10], [11].

Data augmentation: Agresivna augmentacija podataka je esencijalna zbog ograničene veličine TGS dataseta (4,000 slika). Efikasne tehnike uključuju horizontalno i vertikalno flipping, rotacije, elastic deformations, i brightness/contrast varijacije koje simuliraju različite akvizicione uslove [2], [7].

Regularizacija: Strategije kao što su dropout, batch normalization, i label perturbation su kritične za sprečavanje overfitting-a i poboljšanje generalizacije na nove seizmičke istraživačke podatke [6].

4.2 Predlog Pristupa za Istraživanje

Za Salt_Segmentation dataset, predlažem sledeći pristup zasnovan na insights-ima iz literature:

Faza 1: Baseline model

- Implementacija standardne U-Net arhitekture sa ResNet-34 enkoderom pretreniranim na ImageNet
- Korišćenje kombinovane loss funkcije: $0.5 \cdot BCE + 0.5 \cdot Dice$
- Osnovna data augmentation: horizontal flip, vertical flip, random rotation ($\pm 15^\circ$)
- Cilj: Postizanje Dice koeficijenta ~ 0.83 kao baseline

Faza 2: Optimizacija i poboljšanja

- Eksperimentisanje sa različitim enkoder arhitekturama (ResNet-50, EfficientNet, DenseNet)
- Implementacija attention mehanizama (spatial i channel attention)
- Proširena augmentacija: elastic deformations, grid distortion, brightness/contrast jittering
- Weighted loss sa većim težinama na granicama solnih struktura • Cilj: Poboljšanje Dice koeficijenta na $\sim 0.85-0.86$

Faza 3: Ensemble i post-processing

- Kreiranje ensemble-a od 3-5 najboljih modela sa različitim arhitekturama
- Test-time augmentation (TTA) za dodatnu robusnost
- Post-processing: morfološke operacije za smoothing granica, uklanjanje malih outlier regiona
- Cilj: Postizanje Dice koeficijenta >0.87

Faza 4: Analiza i validacija

- Detaljna analiza grešaka: identifikacija tipova solnih struktura gde model greši
- Vizualizacija attention mapa za razumevanje šta model uči
- Testiranje generalizacije na različitim podskupovima podataka • Dokumentacija best practices i lessons learned

4.3 Vizija i Očekivanja

Tehnike pretprocesiranja:

Pretprocesiranje seizmičkih slika može značajno uticati na performanse modela:

- Normalizacija: Standardizacija intenziteta piksela (zero mean, unit variance) ili min-max scaling na $[0,1]$ opseg. Različite normalizacione strategije mogu biti optimalne za različite regione dataseta [7], [8].
- Denoising: Primena Gaussian blur-a ili bilateral filtering-a za redukciju šuma dok se čuvaju ivice. Međutim, treba biti oprezan da se ne izgube fine detalje solnih struktura [8].
- Histogram equalization: Adaptive histogram equalization (CLAHE) može poboljšati kontrast i učiniti solne strukture vidljivijim, posebno u low-contrast regionima [23].
- Multi-scale preprocessing: Kreiranje piramide slika na različitim rezolucijama može pomoći mreži da uhvati feature-e na različitim skalama [1].

Razmatranje augmentacije podataka:

Data augmentation je kritična za sprečavanje overfitting-a na relativno malom TGS datasetu:

- Geometrijske transformacije: Horizontal/vertical flipping, rotacije, scaling, shearing, elastic deformations. Ove transformacije simuliraju različite orijentacije i deformacije solnih struktura [2], [7].
- Intenzitetske transformacije: Random brightness, contrast, gamma adjustments simuliraju različite akvizicione uslove i kvalitet podataka [23].

- Noise injection: Dodavanje Gaussian ili salt-and-pepper šuma može poboljšati robusnost modela na šumne seizmičke podatke [8].
- Mixup i CutMix: Napredne tehnike koje kombinuju više slika mogu dodatno poboljšati generalizaciju [2].

Očekivanja i izazovi:

Očekujem da će glavni izazovi biti:

- Neuravnotežene klase: Solni pikseli često čine <20% ukupne slike. Ovo će zahtevati pažljivo balansiranje loss funkcije i možda sampling strategije [9], [10].
- Varijabilnost solnih struktura: Od malih, kompaktnih struktura do velikih, kompleksnih formacija sa nepravilnim granicama. Model mora biti dovoljno fleksibilan da rukuje ovom varijabilnošću [7], [11].
- Nejasne granice: Prelazne zone između soli i sedimenata mogu biti nejasne u seizmičkim podacima. Attention mehanizmi i edge-focused loss funkcije mogu pomoći [11], [17].
- Generalizacija: Model treniran na TGS datasetu mora generalizovati na različite geografske regione i akvizicione sisteme. Regularizacija i augmentacija će biti ključne [6].

Realistično očekivanje je postizanje Dice koeficijenta između 0.85 i 0.87 sa pažljivo dizajniranim pristupom, što bi bilo konkurentno sa state-of-the-art rezultatima iz literature. Ključ uspeha će biti sistematsko eksperimentisanje, pažljiva analiza rezultata, i iterativno poboljšanje na osnovu insights-a iz grešaka modela.

5.Reference

- [1] Y. Zhang, Y. Zhu, Y. Li, and H. Zhang, "SaltISCG: Interactive Salt Segmentation Method Based on CNN and Graph Cut," *IEEE Transactions on Geoscience and Remote Sensing*, vol. 60, 2022. <https://doi.org/10.1109/TGRS.2022.3172997>
- [2] Y. Babakhin, A. Sanakoyeu, and H. Kitamura, "Semi-supervised Segmentation of Salt Bodies in Seismic Images Using an Ensemble of Convolutional Neural Networks," in *German Conference on Pattern Recognition*, 2019. https://doi.org/10.1007/978-3-030-33676-9_15
- [3] "Salt Segment Identification in Seismic Images of Earth Surface using Deep Learning Techniques," in *Proc. ICEARS*, 2023. <https://doi.org/10.1109/ICEARS56392.2023.10085475>
- [4] M. S. Kiran, S. Kumar, and R. Sharma, "Salt Segment Identification in Seismic Images Using UNet with ResNet," in *Proc. Int. Conf. Intelligent Systems*, 2023. https://doi.org/10.1007/978-981-99-6690-5_36
- [5] A. Kainkaryam, P. Shekar, and M. Srivastava, "Crowdsourcing salt model building: KaggleTGS salt identification challenge," in *Proc. EAGE Conference*, 2019. <https://doi.org/10.3997/2214-4609.201901271>
- [6] M. K. Sen, S. Dutta, and K. Marfurt, "Regularization strategies for deep-learning-based salt model building," *Interpretation*, vol. 7, no. 3, 2019. <https://doi.org/10.1190/INT-20180229.1>
- [7] M. Karchevskiy, I. Ashrapov, and L. Kozinkin, "Automatic salt deposits segmentation: A deep learning approach," *arXiv preprint*, 2018.
- [8] D. S. Bormane, S. S. Patil, and R. K. Jain, "Salt Segmentation in Seismic Imagery Using Deep Learning Techniques," unpublished.
- [9] A. Milosavljević, "Identification of Salt Deposits on Seismic Images Using Deep Learning Method for Semantic Segmentation," *ISPRS International Journal of Geo-Information*, vol. 9, no. 1, p. 24, 2020. <https://doi.org/10.3390/IJGI9010024>
- [10] A. Jadhav, P. Sharma, and K. Patel, "Automatic Salt Segmentation Using Deep Learning Techniques," 2024. <https://doi.org/10.21203/rs.3.rs-4360581/v1>
- [11] Z. Guo, C. Li, X. Wu, and H. Gao, "A Deep Supervised Edge Optimization Algorithm for Salt Body Segmentation," *IEEE Geoscience and Remote Sensing Letters*, vol. 18, no. 6, 2021. <https://doi.org/10.1109/LGRS.2020.3007258>
- [12] M. Guarido, L. Silva, and R. Santos, "Machine learning in geoscience: Using deep learning to solve the TGS Salt Identification challenge," unpublished.
- [13] A. Shukla, "Automated Salt Segmentation in Seismic Images Using U-Net Architecture for

Improved Geological Analysis," *International Journal For Science Technology And Engineering*, vol. 13, no. 12, 2025. <https://doi.org/10.22214/ijraset.2025.66121>

[14] "TGS Salt Identification Challenge," Kaggle Competition, 2018. [Online]. Available: <https://www.kaggle.com/c/tgs-salt-identification-challenge>

[15] J. A. Souza, M. P. Lima, and C. R. Oliveira, "Salt segmentation using deep learning," in *Proc. 16th Int. Congress Brazilian Geophysical Society*, 2019. <https://doi.org/10.22564/16CISBGF2019.219>

[16] J. Li, X. Wang, Y. Zhang, and H. Liu, "Deep Learning-based Model for Automatic Salt Rock Segmentation," *Rock Mechanics and Rock Engineering*, vol. 55, 2021. <https://doi.org/10.1007/S00603-021-02673-Y>

[17] O. M. Saad, Y. Chen, M. Bai, and S. Huang, "Self-attention fully convolutional DenseNets for automatic salt segmentation," *IEEE Transactions on Neural Networks and Learning Systems*, vol. 35, no. 6, 2023. <https://doi.org/10.1109/tnnls.2022.3175419>

[18] F. Li, Z. Zhang, H. Liu, and W. Chen, "SaltFormer: A hybrid CNN-Transformer network for automatic salt dome detection," *Computers & Geosciences*, vol. 193, p. 105772, 2024. <https://doi.org/10.1016/j.cageo.2024.105772>

[19] S. Souadih, K. Benmahammed, and A. Belouchrani, "Accurate identification of salt domes using deep learning techniques: Transformers, generative artificial intelligence and liquid state machines," *Geophysical Prospecting*, vol. 73, no. 3, 2024. <https://doi.org/10.1111/1365-2478.13603>

[20] A. Anitha, R. Kumar, and S. Patel, "Salt Deposits Identification Using Enhanced U-netbased Mixed Attention Loss Function for Semantic Segmentation," in *Proc. ICDSIS*, 2024. <https://doi.org/10.1109/icdsis61070.2024.10594624>

[21] T. M. Muller, B. Guo, and G. Schuster, "Deep-salt: Complete three-dimensional salt segmentation from inaccurate migrated subsurface offset gathers using deep learning," *Geophysical Prospecting*, vol. 72, no. 5, 2024. <https://doi.org/10.1111/1365-2478.13506>

[22] Y. HajNasser, "MultiResU-Net: Neural Network for Salt Bodies Delineation and QC Manual Interpretation," in *Proc. Offshore Technology Conference*, 2021. <https://doi.org/10.4043/31169-MS>

[23] V. S. Arsha, M. Kumar, and P. Singh, "Salt body segmentation in seismic images using mask R-CNN," unpublished.

Kraj dokumenta

Ovaj dokument predstavlja Kontrolnu tačku 1 projekta segmentacije soli u seizmičkim slikama. Teorijska osnova pruža sveobuhvatan pregled problema, postojećih pristupa, i najčešće korišćenih algoritama, sa fokusom na konceptualno razumevanje i pripremu za praktičnu implementaciju.